



Nombre de la práctica	Regresión Lineal			No.	1
Asignatura:	Simulación	Carrera:	INGENIERÍA EN SISTEMAS COMPUTACIONALES	Duración de la práctica (Hrs)	5 horas


NOMBRE DEL ALUMNO: Fabiola Castañeda Mondragón
GRUPO: 3401

1.- Abrir Anaconda desde la terminal:

```
fabiola2004@pc8: ~
base) fabiola2004@pc8:~$ anaconda-navigator
024-09-19 13:21:41,724 - WARNING linux_scaling.get_primary_monitor_name:61
an't detect primary monitor.

arning: Ignoring XDG_SESSION_TYPE=wayland on Gnome. Use QT_QPA_PLATFORM=wayland
to run on Wayland anyway.
ibGL error: MESA-LOADER: failed to open iris: /usr/lib/dri/iris_dri.so: no se p
ede abrir el archivo del objeto compartido: No existe el archivo o el directori
(search paths /usr/lib/x86_64-linux-gnu/dri:\${ORIGIN}/dri:/usr/lib/dri, suff
x _dri)
ibGL error: failed to load driver: iris
ibGL error: MESA-LOADER: failed to open swrast: /usr/lib/dri/swrast_dri.so: no
e puede abrir el archivo del objeto compartido: No existe el archivo o el direc
```

2.- Correr ambiente virtual:



3.- Abrir Jupyter:



4.- Redacción de un ejercicio en Regresión Lineal.

Regresion Lineal: Costo de un incidente de Seguridad.



En este ejercicio se explican los fundamentos basicos de la regresion lineal, aplicada a un caso de uso sencillo relacionado con la Ciberseguridad.

Enunciado del ejercicio.

El ejercicio consiste en predecir el costo de un incidente de seguridad en base al numero de equipos que se han visto afectados. El conjunto de datos es genrado de manera aleatoria.

5.- Comenzamos generando la Base de Datos:

1.- Generacion del DataSet

```
] : import numpy as np

X = 2 * np.random.rand(100, 1)
y = 4 + 3 * X + np.random.randn(100, 1)

print("La longitud del DataSet es: ", len(X))
```


La longitud del DataSet es: 100

6.- Verificamos el DataSet mediante una grafica.

2.- Visualizacion del DataSet


```
: import matplotlib.pyplot as plt
%matplotlib inline

: plt.plot(X, y, "b.")
plt.show()
```



7.- Aquí graficamos puntos azules (b.) con datos de X (equipos afectados) y y (costo del incidente), etiquetando los ejes, y luego muestra la gráfica.

```
plt.plot(X, y, "b.")
plt.xlabel("Equipos afectados (u/1,000)")
plt.ylabel("Costo del Incidente (u/10,000)")
plt.show()
```



8.- Importamos pandas, para poder modificar el DataSet:

3.- Modificacion del DataSet

```
import pandas as pd

data = {'No_Equipos_Afectados': X.flatten(), 'Costo': y.flatten()}
df = pd.DataFrame(data)
df.head(10)
```


	No_Equipos_Afectados	Costo
0	1.416653	7.206953
1	1.469717	10.113362
2	1.232901	7.237528
3	1.349350	8.313659
4	0.077328	4.631944
5	1.392359	7.786886
6	1.360389	7.920949
7	1.083574	6.324954
8	0.416775	3.408366
9	0.510217	5.986208

9.- Aquí lo que hacemos es escalar los valores de dos columnas de un DataFrame (No_Equipos_Afectados y Costo), multiplicando por 1000 y 10,000 respectivamente, y luego convierte los resultados a enteros. Después, muestra las primeras 10 filas del DataFrame.

```
# Escalado del numero de equipos afectados
df['No_Equipos_Afectados'] = df['No_Equipos_Afectados'] * 1000
df['No_Equipos_Afectados'] = df['No_Equipos_Afectados'].astype('int')
# Escalado del Costo
df['Costo'] = df['Costo'] * 10000
df['Costo'] = df['Costo'].astype('int')
df.head(10)
```

	No_Equipos_Afectados	Costo
0	1416	72069
1	1469	101133
2	1232	72375
3	1349	83136
4	77	46319
5	1392	77868
6	1360	79209
7	1083	63249
8	416	34083
9	510	59862

```
plt.plot(df['No_Equipos_Afectados'], df['Costo'], "b.")
plt.xlabel("Equipos afectados")
plt.ylabel("Costo del Incidente")
plt.show()
```



10.- Comenzamos con la realización del modelo:

4.- Construcción del Modelo.

```
|: from sklearn.linear_model import LinearRegression

|: # Construcción del modelo y ajuste de la función de hipótesis
lin_reg = LinearRegression()
lin_reg.fit(df['No_Equipos_Afectados'].values.reshape(-1, 1), df['Costo'].values)

|: LinearRegression
LinearRegression()

|: # Parametro Theta 0
lin_reg.intercept_

|: np.float64(40794.72323638943)


|: # Parametro Theta 1
lin_reg.coef_

|: array([30.72896156])

|: # Predicción para el valor mínimo y máximo para el conjunto de datos de entrenamiento.
X_min_max = np.array([[df["No_Equipos_Afectados"].min()], [df["No_Equipos_Afectados"].max()]])
y_train_pred = lin_reg.predict(X_min_max)

|: # Representación gráfica de la función de hipótesis generada
plt.plot(X_min_max, y_train_pred, "g-")
plt.plot(df['No_Equipos_Afectados'], df['Costo'], "b.")
plt.xlabel("Equipos Afectados")
plt.ylabel("Costo del incidente")
plt.show
```

<function matplotlib.pyplot.show(close=None, block=None)>




11.- Aquí el código utiliza un modelo de regresión lineal (`lin_reg`) para predecir el costo de un incidente, dado que hay 2700 equipos afectados, y luego imprime el costo estimado

5.- Predicción de nuevos ejemplos

```
x_new = np.array([[2700]]) #Numero de equipos afectados.  
# Prediccion del costo que tendria el incidente.  
Costo = lin_reg.predict(x_new)  
print("El costo del incidente seria: $", int(Costo[0]))
```

El costo del incidente seria: \$ 123762

```
plt.plot(df['No_Equipos_Afectados'], df['Costo'], "b.")  
plt.plot(X_min_max, y_train_pred, "g-")  
plt.plot(x_new, Costo, "rs")  
plt.xlabel("Equipos Afectados")  
plt.ylabel("Costo del Incidente")  
plt.show()
```



Conclusión:

Con este ejercicio lo que puedo visualizar como es el comportamiento de diferentes datos de una Base de Datos, mediante regresión lineal.

La regresión lineal es un modelo estadístico que establece una relación lineal entre una variable dependiente (y) y una o más variables independientes (x). Al importar numpy, podemos realizar cálculos.